

MODELAGEM E PREVISÃO DO NÚMERO DE CASOS DE INTERNAÇÃO POR DOENÇAS DO APARELHO RESPIRATÓRIO NA CIDADE DE SÃO PAULO VIA LSTM

Luís Philipe Craveiro Mendes e Matheus Jun Onishi da Silva

Introdução

Compreende-se que há uma estreita relação entre fatores climáticos e a saúde humana, especialmente no que se refere ao sistema respiratório. Condições climáticas adversas podem aumentar a ocorrência de internações hospitalares e, em casos mais graves, levar a óbitos (Arbex 2012). No Brasil, muitas cidades estão em processo de urbanização ou já apresentam intensa urbanização, o que agrava os problemas de saúde pública devido à formação de ilhas de calor, poluição atmosférica e outros fatores climáticos que contribuem para o aumento de doenças respiratórias (Anenberg 2020).

Na área de saúde pública, prever o número de internações esperadas em um determinado período é essencial para o planejamento de recursos e a formulação de políticas. Além disso, compreender o impacto das variáveis explicativas no modelo é crucial para a identificação de medidas preventivas. Neste trabalho, limitamo-nos ao desenvolvimento de um modelo capaz de prever o número de internações, utilizando uma classe de redes neurais apropriada para séries temporais e utilizando covariáveis climáticas.

O estudo concentra-se na modelagem do número de internações por doenças do sistema respiratório na cidade de São Paulo entre os anos de 2018 e 2019. Foram utilizadas como covariáveis a umidade relativa do ar, a temperatura e a concentração de material particulado fino ($PM_{2.5}$). Os dados de internações foram obtidos no DATASUS, enquanto as informações climáticas foram extraídas do Sistema Integrado de Serviços Ambientais (SISAM). Para a modelagem, foi empregado o modelo de redes neurais de Memória Longa de Curto Prazo (LSTM) (Sepp Hochreiter 1997), devido à sua capacidade de capturar padrões temporais complexos nos dados.

Materiais e Métodos

Memória Longa de Curto Prazo (LSTM)

O LSTM é um tipo de rede neural da família de Redes Neurais Recorrentes que funcionam como uma espécie de diversos “mensageiros” que processam os dados que receberam, e transmitem isso para outros mensageiros. Isso cria uma espécie de memória que é compartilhada entre eles e pode fornecer bons resultados como saídas. Essa classe de redes neurais é utilizada em diversos contextos como trabalhos de tradução, reconhecimento de voz etc. (“Understanding LSTM Networks,” n.d.).

Redes Neurais Recorrentes (RNNs) conseguem realizar boas previsões considerando o impacto de informações recentes, entretanto, quando há informações importantes disponíveis no histórico dos dados que impactam em previsões futuras em intervalos cada vez maiores, essa classe de redes neurais se torna ineficiente na tarefa de realizar previsões, visto que não conseguem resgatar esse termo longínquo que impacta a previsão desejada com eficiência. Ou seja, quanto maior o *lag* entre a informação que deseja ser prevista e a informação relevante para tal previsão, menos capaz essa classe de redes realizar previsões precisas. (Bengio 1994) explora essas ideias com mais detalhes. Porém, para o LSTM, o problema de resgatar dados históricos longínquos é solucionado.

O principal objetivo do LSTM é justamente conseguir manter a influência de dados passados em estimativas futuras. Diferentemente de redes neurais recorrentes padrões, ele tem uma estrutura mais complexa. Veja abaixo a ilustração de uma RNN padrão com a única função de ativação tangente hiperbólica:




Figure 1: Fonte: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

Agora veja a estrutura de um módulo do LSTM que será abordado com mais detalhes a diante:




Figure 2: Fonte: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

A Interconexão das Informações




Figure 3: Fonte: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

Note, pela primeira figura acima considerando C_{t-1} uma informação que está passando por um módulo, que C_{t-1} passando por meio de transformações lineares. Primeiramente ele é multiplicado por uma saída de uma função de ativação sigmóide, ou seja, tal informação ganha um peso considerando valores entre 0 e 1, já que estes valores são a imagem da função sigmóide. Em seguida, C_{t-1} passa por mais duas operações que veremos com mais detalhes futuramente. Por enquanto, foquemos nessa primeira operação.

A partir do que foi discutido, podemos entender que a função sigmóide filtra parte da informação contida em C_{t-1} ao multiplicar por valores entre 0 e 1. Veja abaixo o destaque para essa operação inicial:




Figure 4: Fonte: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

continuar a partir daqui com base no primeiro parágrafo de "Step-by-Step LSTM Walk Through" do site de base

Resultados

#Conclusão

Referências

- Anenberg, Susan C. 2020. "Synergistic Health Effects of Air Pollution, Temperature, and Pollen Exposure: A Systematic Review of Epidemiological Evidence." *Environmental Health* 19 (1). <https://doi.org/10.1186/s12940-020-00681-z>.
- Arbex, Marcos Abdo. 2012. "A Poluição Do Ar e o Sistema Respiratório." *Jornal Brasileiro de Pneumologia* 38 (5): 643–55. <https://doi.org/10.1590/s1806-37132012000500015>.
- Bengio, Y. 1994. "Learning Long-Term Dependencies with Gradient Descent Is Difficult." *IEEE Transactions on Neural Networks* 5 (2): 157–66. <https://doi.org/10.1109/72.279181>.
- Sepp Hochreiter, Jürgen Schmidhuber. 1997. "Long Short-Term Memory." *Neural Computation* 9 (8): 1735–80. <https://doi.org/10.1162/neco.1997.9.8.1735>.
- "Understanding LSTM Networks." n.d. <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>.